A collection of small squares in various shades of blue, green, and yellow, scattered in the top right corner of the slide.

Análise de Sentimentos em Filmes

Projeto Aplicado II - Banco de Dados


Juliano Ferrari Faganello Castilho (RA: 10733190)

Ricardo Koozo Taira (RA: 10747687)

Wanderley de Oliveira Junior (RA: 10736901)

Universidade Presbiteriana Mackenzie - EAD 2026


A small cluster of squares in blue, green, and yellow, located in the bottom left corner of the slide.

A collection of small squares in various colors (blue, orange, green, red) scattered in the top right corner of the slide.

O Objetivo do Projeto

Desenvolver um modelo analítico capaz de classificar automaticamente avaliações de filme. O foco é demonstrar como o NLP (Natural Language Processing) pode transformar textos subjetivos em dados estruturados para gerar inteligência de mercado competitiva, conectando as descobertas técnicas às oportunidades de mercado.




A cluster of small squares in various shades of blue, green, and yellow is located in the top right corner of the slide.

O Problema

No cenário atual de consumo de mídia, o volume de avaliações geradas por usuários supera a capacidade de análise humana. O problema central identificado foi a "latência de percepção": empresas do setor muitas vezes demoram semanas para processar o que o público pensa sobre um lançamento, perdendo o timing para ajustes de marketing ou estratégias de retenção de audiência.



A collection of small squares in various shades of blue, green, and yellow, scattered in the top right corner of the slide.

O Gap Identificado


Volume Massivo

Plataformas como o IMDb geram milhares de resenhas diariamente, tornando a análise manual impossível e ineficiente.

Dados Não Estruturados


Textos livres contêm erros gramaticais, gírias e variações linguísticas que desafiam os algoritmos tradicionais.



A collection of small squares in various colors (blue, green, red, yellow) scattered in the top right corner of the slide.

Dataset

- 46.173 registros processados.
 - Base originada do IMDb e traduzida para PT-BR.
 - Campos: Ratings, Resenhas e Gêneros.
- 
- A small cluster of squares in blue, green, and red colors located in the bottom left corner of the slide.

A collection of small squares in various shades of blue, green, and yellow, scattered in the top right corner of the slide.


| Exploratória

Nesta etapa, o objetivo é compreender a composição e a saúde dos dados antes do treinamento.




Total de avaliações por gênero

Aqui é possível notar que os gêneros de drama, romance e comédia lideram a volumetria de avaliações.



Total de avaliações por gênero

O gênero "História/History" possui o maior percentual de notas máximas, enquanto o "Estrangeiro/Foreign" lidera o percentual de notas mais baixas.



Treino

Modelo de classificação por Regressão Logística Binária:

- Reviews separadas entre Positivas (≥ 6) e Negativas (< 6)
- Variáveis preditoras: Vetor TF-IDF de palavras utilizadas nas reviews, desconsiderando stop-words e considerando n-gram de até 2 palavras.
- Divisão treino/teste: 80/20

	Ratings	Reviews	review tratado
0	3.0	It had some laughs, but overall the motivation...	laughs overall motivation characters incompreh...
1	4.0	WAITING TO EXHALE Waiting, and waiting, and wa...	waiting exhale waiting waiting waiting waiting...
2	4.0	Angela Basset was good as expected, but Whitne...	angela basset good expected whitney no range a...
3	5.0	The movie is okay, mediocre might even be the ...	movie okay mediocre might even word describe s...
4	5.0	I got an opportunity to see Waiting To Exhale ...	got opportunity see waiting exhale second time...

Resultados

Acurácia: 0.8400621118012422				
	precision	recall	f1-score	support
Negativo	0.85	0.76	0.80	1654
Positivo	0.83	0.90	0.87	2210
accuracy			0.84	3864
macro avg	0.84	0.83	0.83	3864
weighted avg	0.84	0.84	0.84	3864

-Precision:

Quando o modelo aponta que uma review é POSITIVA, ele acerta em 83% das vezes.
Quando o modelo aponta que uma review é NEGATIVA, ele acerta em 85% das vezes.


-Recall:

O modelo acertou 90% das reviews POSITIVAS.
O modelo acertou 76% das reviews NEGATIVAS.

Verificamos aqui que a maior dificuldade do modelo, por enquanto, é acertar quando a review é NEGATIVA.

Resultados

- 65% dos erros do modelo estão na faixa de reviews com notas de 4 a 6, “neutras”.
- Modelo teve baixo índice de erros nos extremos.



Análise de erros do modelo:

Exemplos de erros do modelo:

Modelo classificou como negativo

Rating: 9

I get what the reviews are saying about the **actors being terrible** and it's a **waste of time** but don't let that dictate your decision. It's no Oscar winning Steven Spielberg 5 stars film but the characters are real and some moments actually leave you on the edge of your seat. Please, before you judge this film: GIVE IT A TRY! you might actually enjoy it. :)

Modelo classificou como positivo

Rating: 4

If this movie had stuck to being a **cute story** about a penguin trying to find love, it would have **been great**. **I love the idea** of penguins finding their perfect match through song. Having a penguin who can't sing and still overcomes being different to get the girl is a **great theme**. Turning the film into a critique on the religious right and an environmental awareness drama was where I lost interest[...]

Comparação entre modelos:

Acurácia calculada para cada modelo:


Modelo	Acurácia Geral	Precisão (+)	Recall (+)	F1-Score (+)	Precisão (-)	Recall (-)	F1 Score (-)
Regressão Logística (Binária)	84%	83%	90%	87%	85%	76%	80%
Naive-Bayes	81,7%	79%	93%	85%	87%	67%	76%
Regressão Logística (3 Rótulos)	71,5%	77%	90%	83%	72%	64%	67%
Árvore de Decisão	65,8%	n/a	n/a	n/a	n/a	n/a	n/a

Legenda: (+) Avaliações Positivas 6-10; (-) Avaliações Negativas 1-5. Nota: A Árvore de Decisão não teve dados granulares extraídos devido à baixa acurácia global.

Comparação entre modelos:

Ao adicionar o rótulo neutro para **regressão logística** temos:

	Precision	Recall	F1-Score
Positivo (8-10)	77%	90%	83%
Negativo (1-4)	72%	64%	67%
Neutro (5-7)	59%	48%	53%

A collection of small squares in various shades of blue, green, and yellow, scattered in the top right corner of the slide.

O Desafio Técnico

O grande gargalo revelado pelos experimentos foi que 65,3% dos erros do modelo se concentram nos ratings 4, 5 e 6. Esta "zona cinzenta" desafia os algoritmos tradicionais, resultando em uma sensibilidade (Recall) de apenas 48% para críticas neutras. Para o negócio, isso significa que opiniões moderadas exigem curadoria humana, pois a linguagem mistura elogios e críticas na mesma sentença.



Resultados e Performance dos Modelos

- **Líder de Performance:** Regressão Logística Binária atingiu 84% de acurácia (F1-Score: 87% Positivos / 80% Negativos).
- **Gargalo do Neutro:** Classe "Neutro" (notas 4-6) derrubou a acurácia para 71,5% e teve o menor Recall (48%), confirmando a alta ambiguidade da zona intermediária.
- **Naive-Bayes:** Atingiu 81,7% de acurácia, mas foi conservador na classe negativa (Recall de 67%).
- **Diferencial Técnico:** O uso de N-grams (1,2) foi essencial para capturar inversões de polaridade (ex: "não é bom").
- **Conclusão:** O ecossistema é altamente eficaz para identificar os extremos (satisfação/rejeição), mapeando com precisão os limites dos algoritmos lineares.

Valor de Negócio

O projeto comprova que a inteligência artificial converte dados brutos em um direcionador estratégico para investimentos de mercado. Do ponto de vista prático, a acurácia de 84% da Regressão Logística Binária traz um retorno operacional imediato: ela permite automatizar a triagem de mais de 80% dos feedbacks extremos (público muito satisfeito ou muito insatisfeito).

Essa automação elimina a necessidade de uma auditoria manual massiva na base de dados, permitindo que a equipe de analistas foque seus esforços exclusivamente nos 20% de opiniões ambíguas e moderadas. Com isso, o ecossistema desenvolvido serve como ferramenta de suporte para decisões de roteiro, direcionamento de campanhas de lançamento e otimização de verba publicitária, reduzindo o risco financeiro em novos projetos cinematográficos.